

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



BÁO CÁO CUỐI KÌ
DỰ BÁO NỒNG ĐỘ BỤI Mịn PM_{2.5}
TẠI HÀ NỘI TRONG 3 THÁNG ĐẦU NĂM 2026

MAT3388 - PHÂN TÍCH CHUỖI THỜI GIAN
Học kỳ 2, Năm học 2025-2026

Giảng viên: **Hoàng Thị Phương Thảo**
 Đỗ Thị Thanh Tâm

Nhóm thực hiện: **Đặng Hải Bình (23001502)**
 Chu Thị Mai Duyên (23001510)
 Nguyễn Trọng Đức (23001961)

Hà Nội - 2026

PHÂN CÔNG NHIỆM VỤ

Công việc	Người phụ trách
Phân chia nhiệm vụ	Đặng Hải Bình
Tìm tài liệu tham khảo	Tất cả các thành viên
Tìm hiểu tổng quan về bộ dữ liệu (EDA)	Đặng Hải Bình
Thực hiện dự đoán với mô hình ARIMA và SARIMA	Nguyễn Trọng Đức
Thực hiện dự đoán với mô hình XGBoost và LSTM	Chu Thị Mai Duyên
Hoàn thiện, chỉnh sửa báo cáo	Tất cả các thành viên
Hoàn thiện chỉnh sửa slide	Tất cả các thành viên

MỤC LỤC

Phân công nhiệm vụ	2
1 Giới thiệu bài toán	6
1.1 Đặt vấn đề	6
2 Cơ sở lý thuyết	8
2.1 Chuỗi thời gian	8
2.2 Mô hình dự báo	8
2.2.1 ARIMA (AutoRegressive Integrated Moving Average)	8
2.2.2 SARIMA (Seasonal ARIMA)	9
2.2.3 XGBoost (Extreme Gradient Boosting)	10
2.2.4 LSTM (Long Short-Term Memory)	11
2.3 Kiểm định tính dừng bằng Augmented Dickey-Fuller (ADF)	12
2.4 Kiểm định tính dừng bằng Kwiatkowski-Phillips-Schmidt-Shin (KPSS)	12
2.5 Hàm tự tương quan (ACF)	13
2.6 Hàm tự tương quan riêng từng phần (PACF)	14
2.7 Phân tích chuỗi thời gian MSTL	14
3 Phân tích và xử lý dữ liệu	16
3.1 Phân tích và xử lý dữ liệu	16
3.1.1 Tổng quan bộ dữ liệu	16
3.1.2 Phân tách chuỗi thời gian	18
3.1.3 Phân tích tương quan với các biến ngoại sinh	19
3.2 Phân tích theo từng giờ	20
3.3 Phân tích theo cụm 6 giờ	22
3.4 Phân tích theo ngày	24
4 Kết quả thực nghiệm	27
4.1 Xây dựng mô hình	27
4.2 Kết quả dự báo	29
4.2.1 Dự báo theo giờ	29
4.2.2 Dự báo theo 6 giờ	32
4.2.3 Dự báo theo ngày	34
5 Kết luận	36

Tài liệu tham khảo

38

Mục lục cho hình ảnh, bảng biểu

Hình 3.1	Biểu đồ các thành phần chuỗi thời gian PM2.5 sau khi phân tách bằng MSTL	18
Hình 3.2	Tương quan hạng Spearman và Mutual Information giữa PM2.5 và các biến ngoại sinh	19
Hình 3.3	Tổng quan chuỗi nồng độ PM2.5 theo giờ tại Hà Nội.	20
Hình 3.4	Biểu đồ ACF và PACF sau khi sai phân bậc 1 ($d = 1$)	21
Hình 3.5	Tổng quan chuỗi nồng độ PM2.5 theo cụm 6 giờ tại Hà Nội.	22
Hình 3.6	Biểu đồ ACF và PACF của chuỗi PM2.5 theo cụm 6 giờ.	23
Hình 3.7	Tổng quan chuỗi nồng độ PM2.5 theo ngày tại Hà Nội.	24
Hình 3.8	Biểu đồ ACF và PACF của chuỗi PM2.5 theo ngày (log).	26
Hình 4.1	Quy trình chuẩn bị và xây dựng các mô hình dự báo	27
Hình 4.2	Mức đóng góp của các đặc trưng đến PM25 với mô hình XGBoost	28
Hình 4.3	Kết quả dự báo theo giờ mô hình ARIMAX	29
Hình 4.4	Kết quả dự báo theo giờ mô hình ARIMA và XGBoost	29
Hình 4.5	Kết quả dự báo theo giờ mô hình LSTM	30
Hình 4.6	So sánh kết quả dự báo của các mô hình theo 6 giờ	32
Hình 4.7	So sánh kết quả dự báo của các mô hình theo ngày	34

Phần 1

GIỚI THIỆU BÀI TOÁN

1.1 Đặt vấn đề

Ô nhiễm không khí do bụi mịn PM2.5 đang trở thành một trong những vấn đề môi trường nghiêm trọng tại nhiều đô thị lớn trên thế giới. Với kích thước khí động học nhỏ hơn $2,5\text{ }\mu\text{m}$, các hạt bụi PM2.5 có khả năng xâm nhập sâu vào hệ hô hấp và hệ tuần hoàn của con người, gây ra nhiều bệnh lý nguy hiểm như bệnh tim mạch, viêm phổi và ung thư phổi. Nhiều nghiên cứu đã chỉ ra rằng nồng độ PM2.5 trong môi trường đô thị chịu ảnh hưởng của nhiều yếu tố khác nhau như điều kiện khí tượng, hoạt động giao thông, công nghiệp và các nguồn phát thải sinh khối. Do đó, việc dự báo chính xác nồng độ PM2.5 có ý nghĩa quan trọng trong công tác cảnh báo ô nhiễm không khí, hỗ trợ quản lý môi trường và bảo vệ sức khỏe cộng đồng.

Trong những năm gần đây, nhiều phương pháp khác nhau đã được áp dụng để dự báo nồng độ PM2.5 theo chuỗi thời gian. Các phương pháp thống kê truyền thống là một trong những hướng tiếp cận sớm nhất trong lĩnh vực này. Trong đó, mô hình ARIMA (*AutoRegressive Integrated Moving Average*) và SARIMA (*Seasonal ARIMA*) được sử dụng rộng rãi để phân tích và dự báo các chuỗi dữ liệu môi trường, dựa trên mối quan hệ tự hồi quy và trung bình trượt của chuỗi dữ liệu quá khứ để dự báo các giá trị tương lai. Mahajan và cộng sự đã áp dụng phương pháp làm mịn theo hàm mũ kết hợp với ARIMA để dự báo nồng độ PM2.5 trong ngắn hạn và cho thấy mô hình có thể đạt được độ chính xác nhất định. Tuy nhiên, các mô hình thống kê truyền thống thường giả định mối quan hệ tuyến tính giữa các biến và gặp hạn chế khi xử lý các chuỗi dữ liệu môi trường phức tạp chịu ảnh hưởng của nhiều yếu tố phi tuyến.

Sự phát triển của các phương pháp học máy (*machine learning*) đã mở ra nhiều hướng tiếp cận mới trong dự báo ô nhiễm không khí. Các thuật toán như Random Forest, Support Vector Machine và Gradient Boosting có khả năng mô hình hóa các mối quan hệ phi tuyến giữa các biến môi trường và khí tượng. Trong đó, XGBoost (*Extreme Gradient Boosting*) là một thuật toán boosting mạnh mẽ, nổi bật với độ chính xác cao và khả năng xử lý hiệu quả các bộ dữ liệu có đặc trưng thời gian thông qua kỹ thuật xây dựng đặc trưng trễ (*lag features*). Tuy nhiên, các mô hình học máy truyền thống thường không được thiết kế chuyên biệt cho dữ liệu chuỗi thời gian, do đó khả năng mô hình hóa các phụ thuộc theo thời gian vẫn còn hạn chế.

Mục tiêu nghiên cứu

Mục tiêu nghiên cứu của báo cáo này bao gồm:

- Ứng dụng các kiến thức đã học vào phân tích chuỗi thời gian.
- Ứng dụng các mô hình ARIMA, SARIMA và XGBoost vào dự báo nồng độ bụi mịn PM2.5.

Phạm vi nghiên cứu

Dữ liệu được sử dụng trong báo cáo được thu thập từ trạm quan trắc chất lượng không khí tại Hà Nội, Việt Nam, bao gồm nồng độ PM2.5 cùng các biến khí tượng đi kèm trong giai đoạn quý I năm 2026, từ ngày 01/01/2026 đến 31/03/2026. Bộ dữ liệu được chia thành tập huấn luyện từ 01/01/2026 đến 24/03/2026 và tập kiểm tra gồm một tuần cuối quý, từ 25/03/2026 đến 31/03/2026. Thông qua các phân tích định lượng và so sánh kết quả dự báo giữa các phương pháp, báo cáo đưa ra nhận xét về khả năng ứng dụng của từng mô hình trong bài toán dự báo chất lượng không khí đô thị.

Phần 2

CƠ SỞ LÝ THUYẾT

2.1 Chuỗi thời gian

Chuỗi thời gian là một tập hợp các quan sát được ghi nhận theo thứ tự thời gian, thường được sử dụng để phân tích và dự báo các hiện tượng thay đổi theo thời gian như doanh số bán hàng, giá cổ phiếu, hoặc các chỉ số kinh tế. Một chuỗi thời gian Y_t có thể được biểu diễn dưới dạng:

$$Y_t = T_t + S_t + C_t + \epsilon_t, \quad (2.1)$$

trong đó:

- T_t : Thành phần xu hướng (trend), thể hiện sự tăng hoặc giảm dài hạn của chuỗi.
- S_t : Thành phần mùa vụ (seasonality), thể hiện các biến động lặp lại theo chu kỳ (ví dụ: doanh số tăng vào mùa lễ).
- C_t : Thành phần chu kỳ (cyclical), thể hiện các dao động không cố định theo thời gian dài.
- ϵ_t : Thành phần nhiễu (noise), là các biến động ngẫu nhiên không giải thích được.

Để dự báo doanh số bán hàng, chuỗi thời gian cần được phân tích để xác định các thành phần này. Một yêu cầu quan trọng đối với các mô hình thống kê như ARIMA và SARIMA là chuỗi phải có tính dừng (stationary), tức là giá trị trung bình và phương sai không thay đổi theo thời gian. Tính dừng có thể được kiểm tra bằng các bài kiểm định như Augmented Dickey-Fuller (ADF) test, trong đó giả thuyết H_0 : chuỗi không dừng; nếu $p\text{-value} < 0.05$, chuỗi được coi là dừng.

2.2 Mô hình dự báo

2.2.1 ARIMA (AutoRegressive Integrated Moving Average)

ARIMA là một mô hình thống kê truyền thống được sử dụng rộng rãi trong phân tích chuỗi thời gian. Tên gọi ARIMA xuất phát từ ba thành phần chính:

- **AR (AutoRegressive)**: Thành phần tự hồi quy, sử dụng các giá trị quá khứ của chuỗi để dự đoán giá trị hiện tại. Mô hình AR(p) được biểu diễn:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t, \quad (2.2)$$

trong đó p là bậc tự hồi quy, ϕ_i là các hệ số, và ϵ_t là nhiễu trắng.

- **I (Integrated)**: Thành phần tích hợp, biểu thị số lần lấy sai phân (differencing) để biến chuỗi không dừng thành dừng. Ví dụ, với $d = 1$, chuỗi được biến đổi thành $Y'_t = Y_t - Y_{t-1}$.
- **MA (Moving Average)**: Thành phần trung bình trượt, sử dụng các sai số quá khứ để dự đoán. Mô hình MA(q) được biểu diễn:

$$Y_t = c + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q}, \quad (2.3)$$

trong đó q là bậc trung bình trượt, θ_i là các hệ số.

Mô hình ARIMA được ký hiệu là ARIMA(p, d, q), trong đó p, d, q là các tham số cần xác định. Để áp dụng ARIMA dự báo doanh số bán hàng, dữ liệu cần được tiền xử lý để đạt tính dừng, sau đó các tham số được chọn dựa trên biểu đồ tự tương quan (ACF) và tự tương quan riêng phần (PACF). ARIMA phù hợp với dữ liệu tuyến tính không có mùa vụ rõ ràng.

2.2.2 SARIMA (Seasonal ARIMA)

SARIMA là phiên bản mở rộng của ARIMA, được thiết kế để xử lý chuỗi thời gian có tính mùa vụ, như doanh số bán hàng tăng vào các kỳ lễ hội. SARIMA bổ sung các thành phần mùa vụ vào mô hình ARIMA, được ký hiệu là SARIMA(p, d, q)(P, D, Q, m), trong đó:

- (p, d, q): Các tham số phi mùa vụ tương tự ARIMA.
- (P, D, Q): Các tham số mùa vụ:
 - P : Bậc tự hồi quy mùa vụ.
 - D : Số lần lấy sai phân mùa vụ.
 - Q : Bậc trung bình trượt mùa vụ.
- m : Chu kỳ mùa vụ (ví dụ: $m = 12$ cho dữ liệu hàng tháng có mùa vụ hàng năm).

Mô hình SARIMA có dạng tổng quát:

$$\Phi_P(B^m)\phi_p(B)(1-B)^d(1-B^m)^D Y_t = \Theta_Q(B^m)\theta_q(B)\epsilon_t, \quad (2.4)$$

trong đó B là toán tử trễ (lag operator), Φ_P và Θ_Q là các đa thức mùa vụ, ϕ_p và θ_q là các đa thức phi mùa vụ.

Trong dự báo doanh số bán hàng, SARIMA đặc biệt hữu ích khi dữ liệu thể hiện các mô hình lặp lại theo mùa (ví dụ: doanh số tăng vào tháng 12). Các tham số (P, D, Q, m) được

xác định dựa trên phân tích mùa vụ của dữ liệu, thường kết hợp với kiểm tra ACF/PACF ở các độ trễ mùa vụ (ví dụ: lag 12, 24).

2.2.3 XGBoost (Extreme Gradient Boosting)

XGBoost là một thuật toán học máy mạnh mẽ dựa trên kỹ thuật gradient boosting, thường được áp dụng cho các bài toán hồi quy và phân loại. Bên cạnh đó, XGBoost còn có thể được sử dụng hiệu quả trong bài toán dự báo chuỗi thời gian, khi dữ liệu được chuyển đổi thành dạng bảng (tabular format) phù hợp với các mô hình học có giám sát.

Không giống như các mô hình thống kê truyền thống như ARIMA hay SARIMA – vốn đòi hỏi dữ liệu phải dừng (stationary) và thường chỉ mô hình hóa được quan hệ tuyến tính – XGBoost không có yêu cầu như vậy. Thay vào đó, nó tập trung vào việc giảm dần sai số dự đoán thông qua các cây quyết định kế tiếp, bằng cách tối ưu hóa một hàm mất mát (loss function) do người dùng chỉ định.

Để sử dụng XGBoost cho dự báo doanh số bán hàng, một bước quan trọng là kỹ thuật trích xuất đặc trưng (feature engineering) từ chuỗi thời gian gốc. Ba loại đặc trưng rất hiệu quả trong trường hợp này là:

- **Độ trễ (Lags):** Là các giá trị lịch sử của các khoảng thời gian trước đó.
- **Trung bình trượt (Moving Average):** Là giá trị trung bình của doanh số trong một cửa sổ thời gian cố định gần hiện tại, ví dụ như trung bình 3 tháng hay 6 tháng gần nhất. Đặc trưng này giúp mô hình nhận biết các xu hướng ngắn hạn, làm mượt dữ liệu và giảm nhiễu.
- **Trung bình tích lũy (Expanding Mean):** Là trung bình của tất cả các giá trị doanh số từ thời điểm đầu đến thời điểm hiện tại. Đặc trưng này thể hiện xu hướng dài hạn và sự thay đổi tổng thể của doanh số theo thời gian.

Ngoài ra, các đặc trưng này có thể được mở rộng với các thống kê khác như: tổng, độ lệch chuẩn, giá trị lớn nhất/nhỏ nhất trong cửa sổ thời gian trượt hoặc mở rộng.

Ưu điểm nổi bật của XGBoost:

- **Khả năng mô hình hóa phi tuyến tính và tương tác giữa các đặc trưng:** Thích hợp với các bài toán có quan hệ phức tạp như doanh số chịu ảnh hưởng bởi nhiều yếu tố không tuyến tính.
- **Hiệu suất cao:** Được tối ưu hóa tốt cho tốc độ huấn luyện và dự đoán nhanh, có khả năng xử lý dữ liệu lớn và hỗ trợ tính toán song song.
- **Kiểm soát overfitting:** Thông qua các kỹ thuật regularization như L1, L2 và pruning thông minh.
- **Tùy biến linh hoạt:** Cho phép người dùng định nghĩa hàm mất mát riêng, phù hợp với các mục tiêu đánh giá khác nhau như MAE, RMSE hoặc MAPE.

Tuy nhiên, do XGBoost không được thiết kế riêng cho chuỗi thời gian, nên việc xây dựng đặc trưng thích hợp để mô hình hiểu được cấu trúc thời gian là điều kiện tiên quyết để đạt được hiệu quả dự báo cao.

2.2.4 LSTM (Long Short-Term Memory)

LSTM là một biến thể đặc biệt của mạng nơ-ron hồi tiếp (Recurrent Neural Network – RNN), được thiết kế để khắc phục vấn đề triệt tiêu gradient (vanishing gradient) thường gặp trong các mạng RNN truyền thống. Nhờ cơ chế bộ nhớ dài hạn, LSTM có khả năng học và ghi nhớ các phụ thuộc dài hạn trong chuỗi dữ liệu, điều mà các mô hình thống kê như ARIMA hay SARIMA khó có thể thực hiện được.

Kiến trúc của LSTM được xây dựng xung quanh một đơn vị gọi là ô nhớ (memory cell), được điều phối bởi ba cổng chính:

- **Cổng quên (Forget Gate):** Quyết định phần thông tin nào từ trạng thái ô nhớ trước đó cần được loại bỏ. Cổng này sử dụng hàm sigmoid để tạo ra một vector giá trị trong khoảng $(0, 1)$, trong đó 0 nghĩa là loại bỏ hoàn toàn và 1 nghĩa là giữ lại toàn bộ.
- **Cổng vào (Input Gate):** Quyết định thông tin mới nào từ đầu vào hiện tại cần được cập nhật vào ô nhớ, kết hợp giữa hàm sigmoid và hàm tanh để kiểm soát lượng thông tin được thêm vào.
- **Cổng ra (Output Gate):** Quyết định phần thông tin nào từ ô nhớ được đưa ra làm đầu ra tại bước thời gian hiện tại, từ đó tạo thành trạng thái ẩn (hidden state) truyền sang bước tiếp theo.

Để sử dụng LSTM cho bài toán dự báo chuỗi thời gian, dữ liệu đầu vào cần được tổ chức lại thành dạng cửa sổ trượt (sliding window), trong đó mỗi mẫu huấn luyện gồm một chuỗi các quan sát liên tiếp trong quá khứ và nhãn tương ứng là giá trị cần dự báo ở bước tiếp theo.

Ưu điểm nổi bật của LSTM:

- **Khả năng học phụ thuộc dài hạn:** Nhờ cơ chế cổng, LSTM có thể ghi nhớ thông tin qua nhiều bước thời gian mà không bị mất mát gradient, phù hợp với các chuỗi có chu kỳ dài hoặc xu hướng phức tạp.
- **Mô hình hóa quan hệ phi tuyến:** Không bị ràng buộc bởi giả định tuyến tính như ARIMA, LSTM có thể nắm bắt các mẫu phi tuyến và tương tác phức tạp trong dữ liệu.
- **Tích hợp biến ngoại sinh:** LSTM có thể dễ dàng mở rộng để nhận thêm các biến đầu vào bổ sung như nhiệt độ, độ ẩm hay tốc độ gió bên cạnh chuỗi thời gian chính, giúp cải thiện độ chính xác dự báo.
- **Khả năng tổng quát hóa tốt:** Với các kỹ thuật chính quy hóa như Dropout và Early Stopping, LSTM có thể tránh được hiện tượng quá khớp (overfitting) trên tập huấn luyện.

Tuy nhiên, LSTM đòi hỏi lượng dữ liệu lớn để huấn luyện hiệu quả và thời gian tính toán cao hơn đáng kể so với các mô hình thống kê truyền thống. Việc lựa chọn các siêu tham số như số lớp ẩn, kích thước cửa sổ đầu vào và tốc độ học cũng có ảnh hưởng lớn đến hiệu suất của mô hình.

2.3 Kiểm định tính dừng bằng Augmented Dickey-Fuller (ADF)

Trong phân tích chuỗi thời gian, tính dừng là một khái niệm nền tảng. Một chuỗi được coi là dừng nếu các đặc trưng thống kê như kỳ vọng, phương sai và hàm tự tương quan không thay đổi theo thời gian. Điều này đảm bảo rằng các mô hình dự báo dựa trên chuỗi thời gian có thể hoạt động ổn định và cho kết quả tin cậy.

Tuy nhiên, trong thực tế, nhiều chuỗi kinh tế và tài chính như doanh thu, chi phí, hay lợi nhuận thường mang tính không dừng do ảnh hưởng bởi xu hướng dài hạn, mùa vụ hoặc các cú sốc từ bên ngoài. Do đó, trước khi tiến hành xây dựng mô hình dự báo như ARIMA, cần phải xác minh tính dừng của chuỗi.

Kiểm định Augmented Dickey-Fuller (ADF) là một trong những phương pháp phổ biến nhất để kiểm tra tính dừng của chuỗi thời gian. Kiểm định này được xây dựng dựa trên giả thuyết không (null hypothesis) rằng chuỗi có nghiệm đơn vị (unit root), tức là không dừng. Nếu giá trị p-value nhỏ hơn mức ý nghĩa (thường là 0.05), ta có thể bác bỏ giả thuyết không và kết luận rằng chuỗi là dừng.

Ngoài ra, ADF còn có thể được thực hiện ở nhiều cấp độ, bao gồm kiểm định chuỗi gốc, sai phân bậc một, hoặc bậc hai tùy theo mức độ không dừng. Trong trường hợp chuỗi không dừng, việc áp dụng các phương pháp biến đổi như sai phân là cần thiết để đảm bảo tính dừng trước khi xây dựng mô hình ARIMA. Việc này giúp đảm bảo rằng kết quả dự báo không chỉ chính xác mà còn ổn định theo thời gian.

2.4 Kiểm định tính dừng bằng Kwiatkowski-Phillips-Schmidt-Shin (KPSS)

Bên cạnh kiểm định Augmented Dickey-Fuller (ADF), kiểm định Kwiatkowski-Phillips-Schmidt-Shin (KPSS) cũng là một công cụ phân tích thống kê quan trọng được sử dụng rộng rãi để xác minh tính dừng của chuỗi thời gian. Trong khi ADF tập trung vào việc tìm kiếm nghiệm đơn vị (unit root), KPSS lại tiếp cận vấn đề từ góc độ hoàn toàn ngược lại. Việc sử dụng kết hợp cả hai kiểm định này giúp cung cấp cái nhìn đối chiếu chéo (cross-validation) toàn diện, đặc biệt khi xử lý các chuỗi dữ liệu thực tế mang tính phức tạp, biến động liên tục và có nhiễu cao như chỉ số chất lượng không khí (ví dụ: nồng độ bụi mịn PM2.5) hay dữ liệu tài chính.

Kiểm định KPSS được thiết lập dựa trên một mô hình hồi quy, trong đó chuỗi thời gian y_t được phân tách thành ba thành phần cốt lõi: một xu hướng tất định (deterministic trend), một bước đi ngẫu nhiên (random walk) và một sai số ngẫu nhiên. Cấu trúc mô hình được biểu diễn qua phương trình:

$$y_t = \xi t + r_t + \varepsilon_t \quad (2.5)$$

Trong đó, $r_t = r_{t-1} + u_t$ là thành phần bước đi ngẫu nhiên với $u_t \sim iid(0, \sigma_u^2)$. Điểm khác biệt lớn nhất của KPSS nằm ở giả thuyết kiểm định. Giả thuyết không (null hypothesis) của KPSS cho rằng phương sai của thành phần bước đi ngẫu nhiên bằng không ($\sigma_u^2 = 0$), tức là chuỗi thời gian là dừng xung quanh một mức cơ sở hoặc một xu hướng (trend-stationary). Ngược lại, giả thuyết đối (alternative hypothesis) cho rằng chuỗi là không dừng.

Cụ thể, hệ thống giả thuyết được phát biểu như sau:

- H_0 : Chuỗi thời gian là dừng (Stationary).
- H_1 : Chuỗi thời gian là không dừng có nghiệm đơn vị (Non-stationary).

Do cách thiết lập giả thuyết ngược lại, nguyên tắc ra quyết định của KPSS cũng trái ngược với ADF. Nếu giá trị p-value nhận được nhỏ hơn mức ý nghĩa thống kê (thường được chọn là 0.05), ta có đủ bằng chứng để bác bỏ giả thuyết không H_0 , đồng nghĩa với việc chuỗi ban đầu là không dừng. Trong trường hợp đó, các kỹ thuật biến đổi dữ liệu như lấy sai phân (differencing) với bậc d phù hợp là bắt buộc trước khi đưa dữ liệu vào huấn luyện các thuật toán như ARIMA hay SARIMA.

Ngược lại, nếu p-value ≥ 0.05 , ta chấp nhận chuỗi thời gian đã đạt được tính dừng. Việc đảm bảo một chuỗi thời gian thực sự dừng thông qua quá trình kiểm định khắt khe bằng cả ADF và KPSS chính là tiền đề cốt lõi để các phương pháp đánh giá mô hình sát với thực tế — như kiểm chứng tịnh tiến (walk-forward validation) — có thể hoạt động ổn định, duy trì độ tin cậy và không bị rò rỉ dữ liệu qua các cửa sổ thời gian trượt (rolling windows).

2.5 Hàm tự tương quan (ACF)

Hàm tự tương quan (Autocorrelation Function – ACF) là một công cụ thống kê quan trọng trong phân tích chuỗi thời gian, dùng để đo lường mức độ tương quan giữa các giá trị trong chuỗi với chính nó tại các độ trễ (lag) khác nhau. Cụ thể, ACF cho biết mức độ liên hệ tuyến tính giữa một giá trị tại thời điểm hiện tại với các giá trị ở những thời điểm trước đó, thông qua hệ số tương quan. Các hệ số này dao động trong khoảng từ -1 đến 1 , phản ánh mức độ và chiều hướng tương quan.

ACF khám phá cấu trúc nội tại của dữ liệu chuỗi thời gian. Khi biểu diễn dưới dạng đồ thị, có thể phát hiện được các đặc điểm như tính chu kỳ, sự lặp lại theo thời gian hoặc các mẫu hành vi tự tương quan kéo dài. Những đặc điểm này đặc biệt hữu ích trong giai đoạn tiền xử lý dữ liệu và lựa chọn mô hình, giúp xác định độ trễ phù hợp cho thành phần MA (Moving Average) trong các mô hình như ARIMA.

ACF còn hỗ trợ đánh giá tính dừng (stationarity) của chuỗi. Một chuỗi không dừng thường có ACF giảm chậm theo độ trễ, trong khi chuỗi dừng có ACF giảm nhanh và dao động quanh giá trị 0. Kiểm tra biểu đồ ACF là một cách tiếp cận trực quan để xác định liệu

chuỗi có cần được chuyển đổi (thông qua sai phân hoặc biến đổi hàm log) trước khi đưa vào mô hình hóa.

2.6 Hàm tự tương quan riêng từng phần (PACF)

Hàm tự tương quan riêng từng phần (Partial Autocorrelation Function – PACF) là một công cụ bổ trợ quan trọng trong việc phân tích mối quan hệ giữa các quan sát trong chuỗi thời gian. Trong khi ACF xem xét tổng thể mối liên hệ giữa một quan sát và tất cả các quan sát trước đó, thì PACF đo lường mức độ tương quan riêng phần giữa một giá trị với giá trị ở độ trễ k , sau khi đã loại bỏ ảnh hưởng từ các độ trễ nhỏ hơn.

PACF cho phép nhận diện mối quan hệ trực tiếp giữa các quan sát trong chuỗi, mà không bị “nhiều” bởi các mối liên hệ gián tiếp thông qua các quan sát trung gian. Mối quan hệ này giúp xác định số bậc trễ thích hợp cho thành phần AR (Autoregressive) trong mô hình ARIMA. Ví dụ, nếu biểu đồ PACF cắt ngang trục hoành sau bậc trễ thứ 2, thì điều đó gợi ý rằng mô hình AR phù hợp nên bao gồm hai bậc trễ.

Phân tích PACF cùng với ACF giúp đưa ra quyết định tốt hơn về việc lựa chọn mô hình phù hợp, đảm bảo mô hình được xây dựng phản ánh đúng cấu trúc dữ liệu và có khả năng dự báo cao.

2.7 Phân tích chuỗi thời gian MSTL

Multiple Seasonal-Trend decomposition using LOESS (MSTL) là một kỹ thuật phân tích chuỗi thời gian hiện đại, mở rộng từ phương pháp STL (Seasonal-Trend decomposition using LOESS) vốn đã rất phổ biến. MSTL được thiết kế để giải quyết những hạn chế của STL truyền thống, đặc biệt là trong các chuỗi thời gian có chứa nhiều thành phần mùa vụ (multi-seasonality), vốn rất thường gặp trong dữ liệu thực tế như thương mại điện tử, tài chính, vận hành hệ thống hoặc giao thông.

Cụ thể, trong khi STL chỉ xử lý được một chu kỳ mùa vụ duy nhất, MSTL cho phép phân rã chuỗi thành nhiều thành phần mùa vụ tương ứng với các chu kỳ khác nhau. Ví dụ, một chuỗi dữ liệu về lưu lượng truy cập website có thể có tính chu kỳ theo giờ trong ngày, theo ngày trong tuần và theo tháng trong năm. MSTL có khả năng bóc tách từng thành phần mùa vụ đó một cách riêng biệt, nhờ sử dụng kỹ thuật hồi quy phi tuyến địa phương (LOESS) để làm mượt và trích xuất các xu hướng cục bộ.

Cấu trúc phân rã của MSTL có thể được biểu diễn như sau:

$$Y_t = T_t + \sum_{i=1}^n S_t^{(i)} + R_t \quad (2.6)$$

Trong đó:

- Y_t : Giá trị quan sát tại thời điểm t

- T_t : Thành phần xu hướng (Trend)
- $S_t^{(i)}$: Thành phần mùa vụ thứ i (Seasonal component)
- R_t : Thành phần nhiễu (Remainder)

Phân rã chuỗi thời gian để làm rõ cấu trúc dữ liệu và phát hiện các đặc điểm bất thường (outliers), xu hướng tăng giảm dài hạn và tính chất lặp lại của dữ liệu ở các mức độ khác nhau.

Sau khi thực hiện phân rã bằng MSTL, các thành phần thu được có thể được sử dụng làm đầu vào cho các mô hình học máy hoặc thống kê như ARIMA, XGBoost, Prophet, ... giúp cải thiện độ chính xác của mô hình vì đã loại bỏ được phần nhiễu và làm nổi bật được quy luật trong dữ liệu.

Ngoài ra, MSTL còn có tính linh hoạt cao vì không yêu cầu chuỗi thời gian phải có độ dài cố định cho mỗi mùa vụ, cho phép xử lý cả những chuỗi bị thiếu dữ liệu hoặc không đều. Điều này làm cho MSTL trở thành một trong những công cụ phân tích thời gian đa mùa vụ mạnh mẽ và dễ triển khai trong thực tiễn.

Phần 3

PHÂN TÍCH VÀ XỬ LÝ DỮ LIỆU

3.1 Phân tích và xử lý dữ liệu

3.1.1 Tổng quan bộ dữ liệu

Dữ liệu được sử dụng trong báo cáo này được thu thập từ trạm quan trắc chất lượng không khí tại Hà Nội, Việt Nam, bao gồm các chỉ số ô nhiễm và khí tượng theo tần suất giờ, trong khoảng thời gian từ ngày 01/01/2026 đến 31/03/2026 (quý I năm 2026). Biên mục tiêu của bài toán là nồng độ PM2.5 (đơn vị: $\mu\text{g}/\text{m}^3$).

Bộ dữ liệu được chia thành hai tập: tập huấn luyện (*train*) bao gồm dữ liệu từ 01/01/2026 đến 24/03/2026, và tập kiểm tra (*test*) là 1 tuần cuối của quý, từ 25/03/2026 đến 31/03/2026. Thông tin tổng quan về hai tập được trình bày trong Bảng 3.1.

Bảng (Tên File)	Số bản ghi	Kích thước	Ý nghĩa
PM25_2026_Q1_train	1.992	1.992×16	Dữ liệu lịch sử quan trắc theo giờ (từ 01/01/2026 đến 24/03/2026), dùng làm tập huấn luyện.
PM25_2026_Q1_test	168	168×16	Dữ liệu quan trắc theo giờ trong 1 tuần tiếp theo (từ 25/03/2026), làm tập kiểm tra thực tế.

Bảng 3.1: Tổng quan kích thước và ý nghĩa các tệp dữ liệu


Mỗi bản ghi trong bộ dữ liệu tương ứng với một thời điểm quan trắc theo giờ, bao gồm 16 trường thông tin. Ý nghĩa và kiểu dữ liệu của từng trường được mô tả trong Bảng 3.2.

Tên trường	Mô tả
Local Time	Thời gian quan trắc theo giờ địa phương (định dạng YYYY-MM-DD HH:MM:SS)
UTC Time	Thời gian quan trắc tương ứng theo chuẩn giờ quốc tế UTC
Country Code	Mã quốc gia của điểm đo (Ví dụ: VN)
AQI	Chỉ số chất lượng không khí tổng hợp (Air Quality Index)
PM25, PM10	Nồng độ bụi mịn PM2.5 và PM10 ($\mu g/m^3$)
CO, NO2, O3, SO2	Nồng độ các khí thải CO, NO ₂ , O ₃ và SO ₂
Temperature	Nhiệt độ môi trường
Relative Humidity	Độ ẩm tương đối (%)
Wind Speed	Tốc độ gió tại thời điểm đo
Pressure	Áp suất khí quyển
Clouds, Precipitation	Mức độ mây phủ và lượng mưa ghi nhận được

Bảng 3.2: Mô tả chi tiết các trường thông tin trong bộ dữ liệu

Bộ dữ liệu không có giá trị thiếu hay bản ghi trùng lặp ở cả hai tập, đảm bảo tính toàn vẹn cho các bước phân tích tiếp theo.

3.1.2 Phân tích chuỗi thời gian



Hình 3.1: Biểu đồ các thành phần chuỗi thời gian PM2.5 sau khi phân tích bằng MSTL

Biểu đồ trên thể hiện các thành phần của chuỗi thời gian sau khi phân tích thành các thành phần: xu hướng (trend), mùa vụ (seasonal), phần dư (residual). Trong đó, thành phần mùa vụ được tính trên 24 giờ (ngày/đêm), 168 giờ (tuần), và 720 giờ (tháng). Kết quả phân tích được trình bày trong Hình 3.1.

Thành phần xu hướng cho thấy nồng độ PM2.5 giảm liên tục và rõ rệt từ đầu tháng 1 đến cuối tháng 2, sau đó ổn định và nhích nhẹ lên đến hết quý. Điều này phản ánh sự cải thiện dần của chất lượng không khí trong quý I, phù hợp với đặc điểm khí hậu Hà Nội khi chuyển từ mùa đông khô lạnh sang đầu xuân ẩm hơn.


Thành phần mùa vụ theo chu kỳ ngày là rõ nét và mạnh nhất trong ba chu kỳ. Quy

luật trong ngày thể hiện rõ ràng: PM2.5 cao vào đêm khuya và sáng sớm, thấp nhất vào buổi trưa khi nhiệt độ tăng cao. Với biên độ dao động lớn trong tháng 1 và thu hẹp dần về cuối quý, cho thấy quy luật ngày/đêm bị chi phối bởi điều kiện khí tượng theo mùa.

Thành phần mùa vụ theo chu kỳ tuần duy trì biên độ ổn định trong suốt cả giai đoạn, phản ánh nhịp hoạt động giao thông và sản xuất lặp lại theo tuần. Thành phần mùa vụ theo chu kỳ tháng có biên độ biến động lớn nhưng do dữ liệu chỉ bao phủ ba tháng, nên được sử dụng để phân tích tham khảo một cách kỹ lưỡng.

Phần dư dao động quanh 0 với biên độ nhỏ hơn đáng kể so với các thành phần mùa vụ, cho thấy MSTL đã giải thích được phần lớn cấu trúc của chuỗi. Tuy nhiên, vẫn xuất hiện một số điểm bất thường vào giữa tháng 2 và đầu tháng 3, có thể liên quan đến các sự kiện đặc biệt như dịp lễ Tết.

3.1.3 Phân tích tương quan với các biến ngoại sinh



Hình 3.2: Tương quan hạng Spearman và Mutual Information giữa PM2.5 và các biến ngoại sinh

Để đánh giá mối quan hệ giữa PM2.5 và các biến ngoại sinh trong bộ dữ liệu, nhóm sử dụng đồng thời hai phương pháp là tương quan hạng Spearman và Mutual Information. Kết quả được thể hiện trong Hình 3.2.


Theo tương quan Spearman, các chất ô nhiễm cùng nguồn gốc như PM10, SO₂, NO₂ và AQI có tương quan dương mạnh nhất với PM2.5, phản ánh việc các chất này cùng phát sinh từ hoạt động giao thông và đốt nhiên liệu. Ngược lại, các biến khí tượng như tốc độ gió, O₃ và nhiệt độ có tương quan âm, cho thấy điều kiện thời tiết thuận lợi giúp phân tán và pha loãng bụi mịn trong không khí.

Kết quả Mutual Information nhìn chung nhất quán với Spearman ở nhóm chất ô nhiễm, trong đó PM10 vượt trội hoàn toàn so với các biến còn lại. Điểm đáng chú ý là nhiệt độ có giá trị Mutual Information tương đối cao dù tương quan Spearman khá yếu, gợi ý rằng quan hệ giữa nhiệt độ và PM2.5 mang tính phi tuyến và không được nắm bắt đầy đủ thông qua hệ số tương quan thông thường.

Kết quả phân tích này không được sử dụng trực tiếp trong mô hình ARIMA do tính chất đơn biến của mô hình. Tuy nhiên, với các mô hình học máy/học sâu như XGBoost và LSTM, bảng phân tích này giúp xem xét các biến tiền năm để đưa vào tập đặc trưng đầu vào, góp phần cải thiện khả năng dự báo của mô hình.

3.2 Phân tích theo từng giờ

Hình 3.3 thể hiện diễn biến nồng độ bụi mịn PM2.5 theo giờ tại Hà Nội trong giai đoạn quan sát.



Hình 3.3: Tổng quan chuỗi nồng độ PM2.5 theo giờ tại Hà Nội.

Dựa trên biểu đồ, chuỗi PM2.5 theo giờ có sự biến động rõ rệt trong suốt giai đoạn quan sát. Nồng độ PM2.5 không duy trì ở mức ổn định mà liên tục xuất hiện các đỉnh ô nhiễm cao xen kẽ với các giai đoạn giảm sâu, cho thấy chuỗi có phương sai thay đổi theo thời gian. Bên cạnh đó, chuỗi thể hiện tính mùa vụ theo chu kỳ hàng ngày với các đỉnh lặp lại theo khung giờ nhất định, tuy nhiên biên độ dao động không đồng đều qua các ngày. Những đặc điểm này cho thấy chuỗi chưa dừng và cần được kiểm định, xử lý trước khi đưa vào mô hình dự báo.

Kiểm định tính dừng

Kiểm định Augmented Dickey-Fuller (ADF) và KPSS được sử dụng đồng thời để kiểm tra tính dừng của chuỗi PM2.5 theo giờ, với các giả thuyết:

- **ADF** – H_0 : Chuỗi có nghiệm đơn vị (không dừng). H_1 : Chuỗi không có nghiệm đơn vị (dừng).
- **KPSS** – H_0 : Chuỗi dừng. H_1 : Chuỗi không dừng.


Dưới đây là kết quả kiểm định trên chuỗi PM2.5 hàng giờ:

Bảng 3.3: Kết quả kiểm định tính dừng – Chuỗi PM2.5 theo giờ

Tham số	ADF	KPSS
Thống kê kiểm định	-4.437	0.731
p-value	0.000255	0.011
Giá trị tới hạn		
1% mức ý nghĩa	-3.433	0.739
5% mức ý nghĩa	-2.863	0.463
10% mức ý nghĩa	-2.568	0.347

Kết quả kiểm định ADF cho thấy giá trị thống kê -4.437 nhỏ hơn các giá trị tới hạn ở cả ba mức ý nghĩa, đồng thời p-value rất nhỏ, cung cấp bằng chứng để bác bỏ giả thuyết gốc và kết luận chuỗi có xu hướng dừng. Tuy nhiên, kết quả kiểm định KPSS cho thấy thống kê 0.731 vượt giá trị tới hạn ở mức 5% (0.463), dẫn đến bác bỏ giả thuyết gốc của KPSS, tức là chuỗi chưa thực sự dừng hoàn toàn. Sự mâu thuẫn giữa hai kiểm định này cho thấy chuỗi PM2.5 theo giờ ở trạng thái *gần dừng* (borderline stationary), nhiều khả năng do thành phần xu hướng giảm dần trong giai đoạn quan sát vẫn còn ảnh hưởng nhất định đến chuỗi.

Phân tích biểu đồ ACF và PACF

**Hình 3.4:** Biểu đồ ACF và PACF sau khi sai phân bậc 1 ($d = 1$)

Sau khi lấy sai phân bậc 1, biểu đồ ACF (Tự tương quan) và PACF (Tự tương quan từng phần) của chuỗi PM2.5 theo giờ (Hình 3.4) cho thấy:

- **Biểu đồ ACF (Tự tương quan):** Có một số giá trị nằm ngoài khoảng tin cậy 95%, cụ thể tại các độ trễ 1, 2, 3 và đặc biệt tại nhóm độ trễ 22, 23, 24, 25, 26. Các đỉnh lặp lại tại vùng độ trễ là bội số của 24 cho thấy dấu hiệu rõ ràng của tính mùa vụ hàng ngày


(chu kỳ 24 giờ). Phần lớn các độ trễ còn lại nằm trong khoảng tin cậy, cho thấy sau sai phân bậc 1 chuỗi đã loại bỏ được phần lớn tự tương quan phi mùa vụ.

- **Biểu đồ PACF (Tự tương quan từng phần):** Giá trị tại độ trễ 1 rất cao, sau đó cắt ngắn (cut off) gần như ngay lập tức, các độ trễ tiếp theo phần lớn nằm trong khoảng tin cậy. Điều này là đặc trưng của chuỗi có thành phần AR (Auto-Regressive) bậc thấp. Ngoài ra, một số giá trị cũng vượt ngưỡng tin cậy tại vùng độ trễ 24-25, củng cố thêm tính mùa vụ chu kỳ 24 giờ.

Biểu đồ ACF và PACF đều củng cố sự tồn tại của tính mùa vụ rõ rệt theo chu kỳ 24 giờ — phản ánh nhịp ngày đêm đặc trưng của dữ liệu chất lượng không khí đô thị — do đó cần xem xét sử dụng mô hình SARIMA (Seasonal ARIMA) để mô hình hóa chuỗi một cách hiệu quả hơn.

3.3 Phân tích theo cụm 6 giờ

Hình 3.5 thể hiện diễn biến nồng độ bụi mịn PM2.5 trung bình theo cụm 6 giờ tại Hà Nội trong giai đoạn quan sát.



Hình 3.5: Tổng quan chuỗi nồng độ PM2.5 theo cụm 6 giờ tại Hà Nội.

Dựa trên biểu đồ, chuỗi PM2.5 theo cụm 6 giờ có sự biến động rõ rệt trong suốt giai đoạn quan sát. So với chuỗi theo giờ, việc lấy trung bình theo cụm 6 giờ đã làm mịn bớt các biến động ngắn hạn, tuy nhiên chuỗi vẫn xuất hiện các đỉnh ô nhiễm cao xen kẽ với các giai đoạn giảm sâu. Tính mùa vụ theo chu kỳ ngày đêm vẫn còn hiện diện, phản ánh qua sự lặp lại có quy luật của các đỉnh dao động trong chuỗi.

Kiểm định tính dừng

Kiểm định Augmented Dickey-Fuller (ADF) và KPSS được sử dụng đồng thời để kiểm tra tính dừng của chuỗi PM2.5 theo cụm 6 giờ, với các giả thuyết:

- **ADF** – H_0 : Chuỗi có nghiệm đơn vị (không dừng). H_1 : Chuỗi không có nghiệm đơn vị (dừng).
- **KPSS** – H_0 : Chuỗi dừng. H_1 : Chuỗi không dừng.


Dưới đây là kết quả kiểm định trên chuỗi PM2.5 theo cụm 6 giờ:

Bảng 3.4: Kết quả kiểm định tính dừng – Chuỗi PM2.5 theo cụm 6 giờ

Tham số	ADF	KPSS
Thống kê kiểm định	-7.046	0.051
p-value	0.000	0.100
Giá trị tới hạn		
1% mức ý nghĩa	-3.451	0.739
5% mức ý nghĩa	-2.871	0.463
10% mức ý nghĩa	-2.572	0.347

Kết quả kiểm định ADF cho thấy giá trị thống kê nhỏ hơn các giá trị tới hạn ở cả ba mức ý nghĩa, đồng thời p-value bằng 0, cung cấp bằng chứng mạnh để bác bỏ giả thuyết gốc và kết luận chuỗi dừng. Kết quả kiểm định KPSS cũng nhất quán khi thống kê kiểm định nhỏ hơn giá trị tới hạn ở tất cả các mức ý nghĩa, không đủ cơ sở bác bỏ giả thuyết gốc, tức là chuỗi dừng. Hai kiểm định đồng thuận cho phép kết luận chuỗi PM2.5 theo cụm 6 giờ có tính dừng, do đó không cần thực hiện sai phân. Phân tích ACF/PACF được tiến hành trực tiếp trên chuỗi gốc để làm rõ cấu trúc tự tương quan.

Phân tích biểu đồ ACF và PACF



Hình 3.6: Biểu đồ ACF và PACF của chuỗi PM2.5 theo cụm 6 giờ.

Biểu đồ ACF và PACF của chuỗi PM2.5 theo cụm 6 giờ (Hình 3.6) cho thấy một số đặc điểm cấu trúc đáng chú ý:


- **Biểu đồ ACF:** Tự tương quan giảm chậm với một số độ trễ vượt ra ngoài khoảng tin cậy 95%, đặc biệt tại các độ trễ đầu. Dạng ACF giảm dần gợi ý sự hiện diện của thành

phần tự hồi quy (AR), đồng thời các đỉnh lặp lại theo chu kỳ phản ánh tính mùa vụ hàng ngày còn hiện diện trong chuỗi.

- **Biểu đồ PACF:** Có một số giá trị đáng kể tại các độ trễ đầu, bao gồm cả giá trị dương và âm, sau đó phần lớn các độ trễ còn lại nằm trong khoảng tin cậy. Dạng PACF này gợi ý chuỗi mang đặc trưng của thành phần AR bậc thấp đến trung bình.
- **Nhận xét chung:** Cả ACF và PACF đều phản ánh cấu trúc tự tương quan rõ ràng tại các độ trễ ngắn, kết hợp với dấu hiệu mùa vụ theo chu kỳ ngày đêm. Do đó, mô hình SARIMA với chu kỳ mùa $S = 4$ là lựa chọn phù hợp để mô hình hóa chuỗi này.

3.4 Phân tích theo ngày

Hình 3.7 thể hiện diễn biến nồng độ bụi mịn PM2.5 trung bình theo ngày tại Hà Nội trong giai đoạn quan sát.



Hình 3.7: Tổng quan chuỗi nồng độ PM2.5 theo ngày tại Hà Nội.

Dựa trên biểu đồ, chuỗi PM2.5 theo ngày không có xu hướng tăng hay giảm rõ ràng trong suốt giai đoạn quan sát, tuy nhiên xuất hiện các đỉnh ô nhiễm cao tập trung vào giữa tháng 1 và đầu tháng 2, sau đó biên độ dao động thu hẹp dần về cuối quý. Phân phối của chuỗi gốc có dạng lệch phải, phản ánh sự xuất hiện của các đỉnh ô nhiễm bất thường với biên độ lớn, gợi ý cần áp dụng biến đổi để ổn định phương sai trước khi kiểm định và mô hình hóa.

Biến đổi logarithm

Do chuỗi gốc có phân phối lệch và phương sai không đồng đều, biến đổi logarithm tự nhiên được áp dụng nhằm ổn định phương sai và đưa phân phối về dạng đối xứng hơn. Sau biến đổi, độ lệch của chuỗi giảm đáng kể, phân phối trở nên cân bằng hơn và phương sai ổn định hơn so với chuỗi gốc. Các bước kiểm định và phân tích tiếp theo được thực hiện trên chuỗi log này.

Kiểm định tính dừng

Kiểm định Augmented Dickey-Fuller (ADF) và KPSS được sử dụng đồng thời để kiểm tra tính dừng của chuỗi PM2.5 theo ngày sau biến đổi logarithm, với các giả thuyết:

- **ADF** – H_0 : Chuỗi có nghiệm đơn vị (không dừng). H_1 : Chuỗi không có nghiệm đơn vị (dừng).
- **KPSS** – H_0 : Chuỗi dừng. H_1 : Chuỗi không dừng.


Dưới đây là kết quả kiểm định trên chuỗi PM2.5 theo ngày sau biến đổi logarithm:

Bảng 3.5: Kết quả kiểm định tính dừng – Chuỗi PM2.5 theo ngày (log)

Tham số	ADF	KPSS
Thống kê kiểm định	-5.499	0.230
p-value	0.000	0.100
Giá trị tới hạn		
1% mức ý nghĩa	-3.514	0.739
5% mức ý nghĩa	-2.898	0.463
10% mức ý nghĩa	-2.586	0.347

Kết quả kiểm định ADF cho thấy giá trị thống kê nhỏ hơn các giá trị tới hạn ở cả ba mức ý nghĩa, đồng thời p-value xấp xỉ bằng 0, cung cấp bằng chứng mạnh để bác bỏ giả thuyết gốc và kết luận chuỗi dừng. Kết quả kiểm định KPSS cũng nhất quán khi thống kê kiểm định nhỏ hơn giá trị tới hạn ở tất cả các mức ý nghĩa, không đủ cơ sở bác bỏ giả thuyết gốc, tức là chuỗi dừng. Hai kiểm định đồng thuận cho phép kết luận chuỗi PM2.5 theo ngày sau biến đổi logarithm có tính dừng, do đó không cần thực hiện sai phân. Phân tích ACF/PACF được tiến hành trực tiếp trên chuỗi log để làm rõ cấu trúc tự tương quan.

Phân tích biểu đồ ACF và PACF




Hình 3.8: Biểu đồ ACF và PACF của chuỗi PM2.5 theo ngày (log).

Biểu đồ ACF và PACF của chuỗi PM2.5 theo ngày sau biến đổi logarithm (Hình 3.8) cho thấy một số đặc điểm cấu trúc đáng chú ý:

- **Biểu đồ ACF:** Tự tương quan giảm nhanh sau độ trễ 1 và phần lớn các độ trễ tiếp theo nằm trong khoảng tin cậy 95%, ngoại trừ một số độ trễ vượt ngưỡng nhẹ ở vùng độ trễ giữa. Không quan sát thấy đỉnh lặp lại có quy luật rõ ràng, cho thấy tính mùa vụ trong chuỗi theo ngày yếu hơn đáng kể so với chuỗi theo giờ hay cụm 6 giờ.
- **Biểu đồ PACF:** Giá trị tại độ trễ 1 đáng kể và dương, sau đó cắt ngắn tương đối nhanh với độ trễ 2 âm rõ rệt. Các độ trễ tiếp theo phần lớn nằm trong khoảng tin cậy, gợi ý chuỗi mang đặc trưng của thành phần AR bậc thấp.
- **Nhận xét chung:** Với ACF giảm nhanh và PACF cắt ngắn sau một vài độ trễ đầu, chuỗi PM2.5 theo ngày sau biến đổi logarithm phù hợp để mô hình hóa bằng ARIMA với bậc thấp. Do tính mùa vụ tuần không biểu hiện rõ trong ACF/PACF ở phạm vi độ trễ quan sát, mô hình SARIMA với chu kỳ mùa $S = 7$ có thể được cân nhắc nhưng cần kiểm chứng thêm trong quá trình lựa chọn mô hình.

Phần 4

KẾT QUẢ THỰC NGHIỆM



Hình 4.1: Quy trình chuẩn bị và xây dựng các mô hình dự báo

Sơ đồ trên minh họa quy trình chuẩn bị dữ liệu và xây dựng các mô hình dự báo. Đối với mô hình XGBoost, chuỗi thời gian đầu vào được phân tách thành ba thành phần chính bằng MSTL: xu hướng (trend), mùa vụ (seasonality) và phần dư (residual), trong đó, các thành phần về mùa vụ được coi là đặc trưng đầu vào của mô hình. Việc phân tách này không chỉ giúp hiểu rõ cấu trúc của chuỗi thời gian mà còn hỗ trợ mô hình học hiệu quả hơn bằng cách loại bỏ các yếu tố gây nhiễu. Sau đó, các đặc trưng về độ trễ, trung bình trượt và thời gian được nhóm cũng trích xuất làm đầu vào cho mô hình XGBoost.

Các mô hình truyền thống ARIMA và SARIMA và mô hình học sâu LSTM được xây dựng trực tiếp dựa trên tập dữ liệu huấn luyện, tận dụng cấu trúc chuỗi thời gian để dự báo.


4.1 Xây dựng mô hình

Với các mô hình truyền thống ARIMA và SARIMA, sau khi thực hiện tối ưu hóa tham số và chọn ra mô hình cho kết quả tốt nhất dựa trên giá trị AIC, các tham số của mô hình như sau:

Bảng 4.1: Các tham số mô hình dự báo theo các khung thời gian

Mô hình	Dự báo 1h	Dự báo 6h	Dự báo 24h
ARIMA	(13, 1, 14)	(5, 0, 8)	(3, 0, 1)
ARIMAX	(3, 0, 1)	(-, -, -)	(3, 0, 1)
SARIMA	(1, 1, 0)(1, 1, 0) ₂₄	(3, 0, 0)(0, 1, 2) ₄	(-, -, -)(-, -, -) _s

Mô hình ARIMA lựa chọn các tham số MA và AR tương đối cao cho thấy mô hình đang cố gắng mô hình hóa các dạng phụ thuộc dài hạn và yếu tố mùa vụ ẩn mà bản thân ARIMA không tích hợp trực tiếp. Đây là một biểu hiện thường gặp khi áp dụng ARIMA cho chuỗi có tính mùa vụ mạnh nhưng không được xử lý bằng phần mùa vụ chuyên biệt. Ngược lại, các mô hình ARIMAX hay SARIMA tận dụng được tốt tính mùa vụ và các đặc trưng ngoại sinh tương ứng nên bậc của mô hình thấp hơn đáng kể.




Hình 4.2: Mức đóng góp của các đặc trưng đến PM25 với mô hình XGBoost


Kết quả mô hình XGBoost cho thấy nồng độ PM2.5 chịu chi phối mạnh nhất bởi yếu tố chu kỳ thời gian (hour, month, rolling_3h). Đối với các biến ngoại sinh, tốc độ gió (Wind Speed) và độ ẩm (Relative Humidity) cũng là hai tác nhân khí tượng ảnh hưởng lớn nhất đến quá trình khuếch tán và ngưng kết bụi mịn, điều này là hợp lý trong thực tế. Ngược lại, nhóm biến phân loại theo tuần (day_of_week, is_weekend) có mức đóng góp không đáng kể, chứng tỏ sự biến thiên của PM2.5 phụ thuộc chủ yếu vào động lực học khí quyển và chu kỳ ngày/mùa thay vì thói quen sinh hoạt theo tuần.

4.2 Kết quả dự báo


4.2.1 Dự báo theo giờ



Hình 4.3: Kết quả dự báo theo giờ mô hình ARIMAX



Hình 4.4: Kết quả dự báo theo giờ mô hình ARIMA và XGBoost



Hình 4.5: Kết quả dự báo theo giờ mô hình LSTM

Với dữ liệu nồng độ bụi mịn PM2.5 theo từng giờ dao động cực kỳ mạnh và ngẫu nhiên dưới tác động tức thời của luồng giao thông hay sự thay đổi thời tiết trong ngày, các mô hình truyền thống họ ARIMA hầu như cho kết quả không tốt: ARIMA chỉ có thể cho ra một đường dự báo đi ngang, trong khi ARIMAX dù dường như được nhập điệu ngày/đêm do được học từ cả những biến ngoại sinh nhưng dải sai số lại quá rộng, cho thấy độ rủi ro cao.

Khá hơn một chút, mô hình XGBoost đã bắt kịp được hướng di chuyển lên xuống của chuỗi dữ liệu nhờ khả năng học được quan hệ phi tuyến, nhưng vì nhiễu theo giờ quá lớn nên vẫn chưa thể dự đoán được chính xác các đỉnh và đáy của dữ liệu.

Ở đây, mô hình học sâu LSTM với kiến trúc mạng nơ-ron là mô hình cho kết quả khớp nhất với dữ liệu thực tế, chứng minh khả năng ghi nhớ diễn biến tuần tự để có thể học được các quy luật ngầm phức tạp của mình và bắt được gần như hoàn toàn các đỉnh và đáy.

Mô hình	Thực nghiệm	MAE	RMSE	MAPE (%)
ARIMA	Không biến ngoại sinh	14.66	18.90	25.03
	Có biến ngoại sinh	15.97	21.52	26.57
SARIMA	Không biến ngoại sinh	16.42	20.39	28.39
	Có biến ngoại sinh	—	—	—
XGBoost	Không biến ngoại sinh	9.83	12.45	17.62
	Có biến ngoại sinh	8.12	10.78	14.85
LSTM	Không biến ngoại sinh	7.91	10.22	13.94
	Có biến ngoại sinh	6.34	8.56	11.27

Bảng 4.2: So sánh kết quả dự báo giữa các mô hình theo giờ


Cụ thể, kết quả dự báo tại Bảng 4.2 cho thấy nhóm mô hình học máy và học sâu (XGBoost, LSTM) cho kết quả vượt trội so với nhóm thống kê truyền thống, tốt nhất là mô hình LSTM kết hợp với các biến khí tượng. Trong khi ARIMA và SARIMA có sai số lớn (MAPE > 25%), các mô hình XGBoost và LSTM đã giảm đáng kể sai số, cho thấy khả năng xử lý tốt các biến động phi tuyến của dữ liệu bụi mịn.

Bên cạnh đó, việc tích hợp các yếu tố khí tượng giúp tối ưu hóa rõ rệt độ chính xác cho LSTM và XGBoost. Ngược lại, sai số của ARIMAX tăng lên khi thêm biến ngoại sinh,

minh chứng cho việc các mô hình tuyến tính khó khai thác hiệu quả mối tương quan phức tạp giữa các yếu tố môi trường.

Tóm lại, đối với dữ liệu tần số cao và chứa nhiều sự thay đổi như chuỗi PM2.5 theo giờ, các phương pháp tuyến tính hay dạng cây quyết định là chưa đủ, kiến trúc mạng nơ-ron vẫn là một kiến trúc cần được lưu tâm và thực nghiệm. Tuy nhiên, với các mô hình học sâu cần cân bằng giữa độ chính xác và thời gian huấn luyện để có thể tối ưu chi phí.

4.2.2 Dự báo theo 6 giờ



Hình 4.6: So sánh kết quả dự báo của các mô hình theo 6 giờ

Với khung 6 giờ, tuy các nhiễu ngắn hạn được làm mượt nhưng việc lấy trung bình lại khiến mô hình khó phản ứng kịp trước những đợt bùng phát ô nhiễm nhanh chóng giữa các buổi trong ngày. Kết quả cho thấy hầu như các mô hình họ ARIMA đều cho kết quả không tốt: ARIMA vẫn đi ngang, SARIMA và SARIMAX dù có tính chu kỳ nhưng trái ngược hoàn toàn với kết quả thực tế do không thể phản ứng kịp thời với các biến động mạnh, đặc biệt ở các đỉnh ô nhiễm.

Với XGBoost, mô hình này vẫn khá tốt ở khung 6 giờ, có khả năng học được các quan hệ phi tuyến phức tạp ngay cả khi không cần các biến ngoại sinh. Ngược lại, mô hình LSTM lại lộ rõ nhược điểm ở các tập dữ liệu nhỏ do không đủ không gian mẫu để tối ưu trọng số. Do đó, thay vì mạo hiểm dự báo các đỉnh/đáy để bị phạt nặng bởi hàm mất mát (như MSE), mạng chọn cách an toàn nhất: dự báo một đường tiệm cận với giá trị trung bình của chuỗi để giữ cho sai số luôn ở mức chấp nhận được.


Mô hình	Thực nghiệm	MAE	RMSE	MAPE (%)
ARIMA	Không biến ngoại sinh	14.00	17.67	24.69
	Có biến ngoại sinh	—	—	—
SARIMA	Không biến ngoại sinh	13.76	17.73	25.02
	Có biến ngoại sinh	—	—	—
XGBoost	Không biến ngoại sinh	11.04	12.82	19.42
	Có biến ngoại sinh	10.91	13.05	16.46
LSTM	Không biến ngoại sinh	11.85	13.64	18.79
	Có biến ngoại sinh	15.40	19.95	22.31

Bảng 4.3: So sánh kết quả dự báo giữa các mô hình theo 6h

Đáng chú ý, việc tích hợp biến ngoại sinh mang lại tác động trái ngược giữa các mô hình: trong khi XGBoost cải thiện được độ chính xác thì hiệu suất của LSTM lại sụt giảm đáng kể, với chỉ số MAE tăng từ 11.85 lên 15.40. Như đã lý giải, càng nhiều đặc trưng được học lại càng lộ rõ yếu điểm của LSTM trên kích thước dữ liệu quá bé.

Tóm lại, mô hình XGBoost khi kết hợp với biến ngoại sinh được xác định là phương án tối ưu nhất trong thực nghiệm này, đạt sai số thấp nhất với MAE là 10.91 và MAPE là 16.46%. Ngược lại, các mô hình thống kê như ARIMA và SARIMA ghi nhận mức sai số MAPE khá cao (xấp xỉ 25%), cho thấy hạn chế của các phương pháp này trong việc xử lý các biến động phức tạp của dữ liệu bụi mịn trong khoảng dự báo cách xa nhau.

4.2.3 Dự báo theo ngày



Hình 4.7: So sánh kết quả dự báo của các mô hình theo ngày

Tương tự với dữ liệu khi được lấy trung bình theo ngày, XGBoost vẫn là mô hình tối ưu nhất ngay cả khi dữ liệu quá bé. Tuy nhiên, vẫn tồn tại tình trạng trễ pha do sự phụ thuộc quá mức vào giá trị của ngày hôm trước. LSTM vẫn cho kết quả không tốt với tập dữ liệu hạn chế này.

Đáng chú ý, mô hình thống kê truyền thống ARIMA lại thể hiện khá tốt ở dữ liệu này khi được cấp thêm dữ liệu môi trường. Đường dự báo của ARIMAX bám sát nhịp độ thực tế, bắt trúng các điểm uốn quan trọng (như đỉnh ô nhiễm ngày 26/03 và nhịp giảm sâu ngày 29/03), chứng minh nồng độ PM2.5 theo ngày chịu sự chi phối quyết định bởi các yếu tố khí tượng tức thời.

Mô hình	Thực nghiệm	MAE	RMSE	MAPE (%)
ARIMA	Không biến ngoại sinh	10.02	11.63	20.92
	Có biến ngoại sinh	5.17	6.43	10.72
XGBoost	Không biến ngoại sinh	7.14	9.17	14.23
	Có biến ngoại sinh	9.19	10.04	18.61
LSTM	Không biến ngoại sinh	9.81	11.51	19.47
	Có biến ngoại sinh	11.84	13.53	23.14

Bảng 4.4: So sánh kết quả dự báo giữa các mô hình theo ngày

Kết quả thực nghiệm dự báo theo ngày tại Bảng 4.4 cho thấy mô hình ARIMA kết hợp biến ngoại sinh (ARIMAX) đạt hiệu quả tối ưu nhất với các chỉ số sai số thấp nhất toàn diện, cụ thể là MAE đạt 5.17 và MAPE đạt 10.72%, giảm hơn một nửa sai số so với khi chỉ sử dụng dữ liệu tự hồi quy và vượt trội hơn hẳn so với mô hình học máy và học sâu

Tuy nhiên, việc đưa thêm biến ngoại sinh vào XGBoost và LSTM mang lại tác động trái ngược hoàn toàn. Có thể thấy cả 2 mô hình đều bị sụt giảm hiệu suất đáng kể với sai số MAPE tăng lần lượt lên mức 18.61% và 23.14%. Điều này cho thấy đối với bài toán dự báo theo khung thời gian 24 giờ, mô hình ARIMAX có sự ổn định và khả năng tương thích với các yếu tố tác động bên ngoài tốt hơn so với các mô hình phức tạp khác.

Phần 5

KẾT LUẬN

Qua quá trình xây dựng và đánh giá các mô hình dự báo (ARIMA, SARIMA, ARIMAX, XGBoost và LSTM) trên ba khung thời gian khác nhau, nghiên cứu nhận thấy sự biến thiên của nồng độ bụi mịn PM2.5 phụ thuộc chủ yếu vào động lực học khí quyển (như tốc độ gió, độ ẩm) và chu kỳ ngày/mùa, trong khi các thói quen sinh hoạt theo tuần mang lại mức đóng góp không đáng kể.

Với dự báo theo khung thời gian 1 giờ, mô hình học sâu LSTM kết hợp với các biến ngoại sinh (khí tượng) thể hiện sự vượt trội hoàn toàn với sai số MAPE thấp nhất đạt 11.27%. Khả năng ghi nhớ diễn biến tuần tự giúp LSTM học được các quy luật ngầm phức tạp, bắt được gần như hoàn toàn các đỉnh và đáy của dữ liệu nhiều nhiễu, điều mà các mô hình truyền thống họ ARIMA không làm được.

Với dự báo theo khung thời gian 6 giờ, khi dữ liệu được lấy trung bình làm giảm số lượng không gian mẫu, mô hình XGBoost kết hợp biến ngoại sinh trở thành phương án tối ưu nhất với MAPE là 16.46%. Trong khi đó, mô hình LSTM bộc lộ rõ nhược điểm trên tập dữ liệu nhỏ do không đủ dữ liệu để tối ưu trọng số, dẫn đến sự sụt giảm hiệu suất đáng kể.

Với dự báo theo khung thời gian 24 giờ (theo ngày), mô hình thống kê truyền thống ARIMAX lại chứng minh được hiệu năng xuất sắc khi đạt sai số MAPE thấp nhất toàn diện ở mức 10.72%. Đường dự báo của ARIMAX bám sát nhịp độ thực tế và bắt trúng các điểm uốn quan trọng nhờ tương thích tốt với dữ liệu môi trường. Ngược lại, việc bổ sung biến ngoại sinh vào XGBoost và LSTM ở khung thời gian này lại gây ra tác động tiêu cực và làm tăng sai số.

Tổng kết lại, thực nghiệm cho thấy không có một phương pháp dự báo nào là tối ưu cho mọi trường hợp. Với dữ liệu tần số cao và chứa nhiều thay đổi đột ngột như chuỗi PM2.5 theo giờ, kiến trúc mạng nơ-ron như LSTM là sự lựa chọn cần thiết. Tuy nhiên, đối với các khung thời gian có khoảng cách dự báo xa hơn (6 giờ hoặc theo ngày) cùng tập dữ liệu nhỏ, các mô hình học máy dạng cây (XGBoost) hoặc mô hình thống kê tuyến tính truyền thống (ARIMAX) lại cho thấy độ ổn định và hiệu quả thực tiễn cao hơn. Việc lựa chọn mô hình cũng như quyết định sử dụng biến ngoại sinh cần được cân nhắc kỹ lưỡng dựa trên đặc thù của từng khung thời gian dự báo.

Trong tương lai, nhóm hướng đến thực nghiệm thêm các phương pháp lai như ARIMAX-LSTM nhằm kết hợp khả năng dự báo dài hạn của mô hình thống kê với sức mạnh xử lý biến động phi tuyến của mạng nơ-ron. Bên cạnh đó, có thể tích hợp dữ liệu không gian - thời gian từ các trạm quan trắc lân cận để mô phỏng chính xác hơn quá trình khuếch tán của bụi mịn. Cuối cùng, việc bổ sung các biến ngoại sinh mới như mật độ giao thông và triển khai mô hình thành một hệ thống dự báo tự động theo thời gian thực sẽ là những định hướng quan trọng giúp nâng cao tính ứng dụng thực tiễn của dự án này.

TÀI LIỆU THAM KHẢO

- [1] George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel, Greta M. Ljung (2015), *Time Series Analysis: Forecasting and Control*. 5th ed. Hoboken, NJ: Wiley.
- [2] James D. Hamilton (1994), *Time Series Analysis*. Princeton, NJ: Princeton University Press.
- [3] Rob J. Hyndman, George Athanasopoulos (2021), *Forecasting: Principles and Practice*. 3rd ed. OTexts. (available at <https://otexts.com/fpp3/>).
- [4] Penn State Department of Statistics (2026), *STAT 510: Applied Time Series Analysis*. Online course material. (available at <https://online.stat.psu.edu/stat510/>).
- [5] Ho Chang-Hoi, Ingyu Park, Hye-Ryun Oh, Hyeon-Ju Gim, Sun-Kyong Hur, Jinwon Kim, Dae-Ryun Choi (2021), *Development of a PM2.5 Prediction Model Using a Recurrent Neural Network Algorithm for the Seoul Metropolitan Area, Republic of Korea*. Atmospheric Environment, Vol. 245, Article 118027. (available at <https://doi.org/10.1016/j.atmosenv.2020.118027>).
- [6] Sasira Choojam, Jularat Chumnaul, Khanittha Wichitchanya-Nun Jetwanna (2024), *Accurate Model for Forecasting PM2.5 Concentrations in Hat Yai, Songkhla, Thailand: The ARIMA-ANN-REG Hybrid Approach via AAR4PM*. EnvironmentAsia, Vol. 17(2), pp. 1–15. (available at <https://doi.org/10.14456/ea.2024.16>).